

音频模态低精度世界模型判据的可行性研究：负结果链与两段式视界模型

【作者姓名】*

（【作者单位名称】 【城市】 【邮编】）

摘要： [目的] 判据框架（误差放大率 a 、崩坏视界 T_{crash} 、预测余量 margin ）的模态无关性是本系列的核心主张，音频模态是其首个试金石；本文系统检验音频潜码判据的可行性。

[方法] 程序化音效三级设计（正弦/带通噪声/谐波） $\times$ 编码器两路线（零训练频带能量/mel+CNN 端到端） $\times$ 预注册判据门（红线/G1/G2/G3）共五次实验； η 注入十档扫描检验 T_{crash} 理论曲线；音画探针机检对齐断言。

[结果] 五次判据门全 FAIL 但失败模式互不相同且可诊断（信息贫乏/反预测性/表示坍塌），红线五次全 PASS（瞬态保留稳健）；两段式视界模型 $h^*(\eta)=\min(T_{\text{crash}}(a, \eta), h_{\text{sat}})$ 成立—— T_{crash} 公式适用条件划定（确定性系统）；音画探针机检断言全过。

[局限] 音频信号均为人工合成（真实音频频谱结构更复杂，负结果不直接外推）；判据门阈值为约定值；18 步窗口内饱和值区分度有限。

[结论] 音频判据在 mel 能量潜码口径下不可测（本质负面结果），根因 =mel 能量对频率滑动响应微弱；三条出路已标记（波形级潜码/能量调制/真实音频数据）；判据门机制被证明能有效防止资源浪费。

关键词： 世界模型；解析核；误差放大率；混合架构；物理坐标

分类号： TP183

Feasibility of audio-modality criteria for low-precision world models: a negative-result chain and a two-regime horizon model

【Author Name】

（【Department, University, City Postal-code, China】）

Abstract: [Objective] The modality-independence of the criteria framework (amplification rate a , collapse horizon T_{crash} , prediction margin) claims applicability to any latent-space dynamics; audio is its first testbed outside vision.

[Methods] Three-tier programmatic sound design (sine / band-pass noise / harmonic) $\times$ two encoder routes (zero-training filterbank / mel+CNN end-to-end) $\times$ a pre-registered criteria gate (red-line / G1 / G2 / G3), five experiments total; a ten-point η -injection scan tests the T_{crash} theoretical curve; an audiovisual probe with machine-checked alignment.

[Results] All five gates FAILED with distinct, diagnosable failure modes (information poverty / anti-predictiveness / representation collapse), while the red line passed all five (transient retention is robust); a two-regime horizon model $h^*(\eta)=\min(T_{\text{crash}}(a, \eta), h_{\text{sat}})$ holds —the applicability condition of the T_{crash} formula is bounded to deterministic systems; the audiovisual probe passed all alignment assertions.

[Limitations] All audio signals are synthetic (real-audio spectra are more complex); gate thresholds are conventions; the 18-step window limits saturation resolution.

[Conclusions] Audio criteria are unmeasurable under mel-energy latents (an essential negative result) due to weak spectral response to frequency sliding; three escape routes are marked (waveform latents / energy modulation / real audio data); the gate mechanism demonstrably prevents resource waste.

Keywords: World model; Analytic core; Amplification rate; Hybrid architecture; Physical coordinates

本文系【基金项目名称】（项目编号：【项目编号】）的研究成果之一。 * 通讯作者（E-mail: 【通讯作者 E-mail】）

[目的] 判据框架（误差放大率 a 、崩坏视界 T_{crash} 、预测余量 margin ）的模式无关性是本系列的核心主张，音频模态是其首个试金石；本文系统检验音频潜码判据的可行性。[方法] 程序化音效三级设计（正弦/带通噪声/谐波） $\times$ 编码器两路线（零训练频带能量/mel+CNN 端到端） $\times$ 预注册判据门（红线/G1/G2/G3）共五次实验； η 注入十档扫描检验 T_{crash} 理论曲线；音画探针机检对齐断言。[结果] 五次判据门全 FAIL 但失败模式互不相同且可诊断（信息贫乏/反预测性/表示坍塌），红线五次全 PASS（瞬态保留稳健）；两段式视界模型 $h^*(\eta)=\min(T_{\text{crash}}(a, \eta), h_{\text{sat}})$ 成立—— T_{crash} 公式适用条件划定（确定性系统）；音画探针机检断言全过。[局限] 音频信号均为人工合成（真实音频频谱结构更复杂，负结果不直接外推）；判据门阈值为约定值；18 步窗口内饱和值区分度有限。[结论] 音频判据在 mel 能量潜码口径下不可测（本质负面结果），根因 =mel 能量对频率滑动响应微弱；三条出路已标记（波形级潜码/能量调制/真实音频数据）；判据门机制被证明能有效防止资源浪费。

关键词：世界模型；解析核；误差放大率；混合架构；物理坐标

分类号：TP183

Abstract

[Objective] The modality-independence of the criteria framework (amplification rate a , collapse horizon T_{crash} , prediction margin) claims applicability to any latent-space dynamics; audio is its first testbed outside vision. [Methods] Three-tier programmatic sound design (sine / band-pass noise / harmonic) $\times$ two encoder routes (zero-training filterbank / mel+CNN end-to-end) $\times$ a pre-registered criteria gate (red-line / G1 / G2 / G3), five experiments total; a ten-point η -injection scan tests the T_{crash} theoretical curve; an audiovisual probe with machine-checked alignment. [Results] All five gates FAILED with distinct, diagnosable failure modes (information poverty / anti-predictiveness / representation collapse), while the red line passed all five (transient retention is robust); a two-regime horizon model $h^*(\eta)=\min(T_{\text{crash}}(a, \eta), h_{\text{sat}})$ holds —the applicability condition of the T_{crash} formula is bounded to deterministic systems; the audiovisual probe passed all alignment assertions. [Limitations] All audio signals are synthetic (real-audio spectra are more complex); gate thresholds are conventions; the 18-step window limits saturation resolution. [Conclusions] Audio criteria are unmeasurable under mel-energy latents (an essential negative result) due to weak spectral response to frequency sliding; three escape routes are marked (waveform latents / energy modulation / real audio data); the gate mechanism demonstrably prevents resource waste.

Keywords: World model; Analytic core; Amplification rate; Hybrid architecture; Physical coordinates

1 引言

判据框架（误差放大率 a 、崩坏视界 T_{crash} 、预测余量 margin ）的模式无关性是本系列工作的核心主张——框架作用在潜空间动力学上，理论上与模态无关。前期工作在视觉模态上完成了框架的两域验证（scene/pusht），但主张不等于实证：音频模态的 $a/\text{margin}/T_{\text{crash}}$ 是否同样可测、可测的话数值形态如何，从未被检验。

本文是音频模态判据可行性的系统研究。结论以五次判据门实验的完整负结果链为主体：三种音色设计 $\times$ 两种编码器路线全部未过预注册门控，但每次失败的失败模式不同且可诊断——负结果链最终收敛到两个结构性根因（端到端

表示坍塌、mel 能量对频率滑动的响应微弱），并导出一个两段式视界模型的修正。全程零外部数据依赖（程序化合成音效），判据门机制证明了其在防止资源浪费上的价值。

贡献三条：(i) 音频判据可行性的完整负结果链与根因诊断（可复用的失败模式分类）；(ii) 两段式视界模型 $h(\eta) = \min(T_{\text{crash}}(a, \eta), h_{\text{sat}})$ —— T_{crash} 公式适用条件（确定性系统）的实验划定；(iii) 音画探针的最小可行演示（清晰 + 有声 + 正确三合一，音画对齐机检断言）。

2 方法

2.1 程序化音效三级设计

音频内容全部程序化合成（与 MM 视觉帧严格同步，12.5fps/帧 80ms=1920 样本 @24kHz），三级设计对应三次判据门：

- 一级·正弦纯音：数字 x 位置 → 基频滑动（200-1400Hz）。单频窄峰，帧间频谱近恒定；
- 二级·带通噪声：数字 x 位置 → 带通噪声中心频率（300-1500Hz，带宽 250Hz）。宽带，帧间频谱随机波动（噪声逐帧独立采样）；
- 三级·谐波音色：数字 x 位置 → 基频（150-900Hz）+ 8 谐波（幅度 1/k）。宽带且完全确定性（位置滑动 → 全部谐波一起移动）。

撞墙事件叠加冲击音（白噪 burst × 指数衰减 + 90Hz 敲击），立体声 pan = 撞点 x 位置。

2.2 编码器两路线与判据门

- 零训练路线：FFT → 64 三角滤波带能量 → log1p → 64 维（固定，无坍塌可能）；
- 学习路线：mel 式谱图（8 子窗 × 64 带）→ 轻量 CNN → 64 维，端到端与 Koopman 动力学联合训练。

判据门（预注册）：红线（撞墙事件窗/平稳窗的潜码距离比 > 1.5，瞬态保留）；G1 a 可测（有限）；G2 margin 曲线非饱和且有视界 CI 下界 > 0（逐序列配对 bootstrap, B=2000）；G3 量化轴有梯度（b=4 首崩 < b=12 首崩）。任一不过即判 FAIL。

2.3 η 注入扫描与两段式模型检验

single ($a=+0.66$) 与 koop ($a=+0.26$) 两模型 × η 注入十档 (log 均匀 0.005-1.0) × 128 序列 × 18 步。 $h(\eta)$ 定义 (margin 口径)：逐序列 $\text{margin}(\cos \text{pred} - \cos \text{copy})$ 过零视界的中位数。理论曲线 $T_{\text{crash}}(\eta) = \ln(1 + \delta(\eta)(e^a - 1)/a)$, $\delta(\eta)$ 为唯一拟合参数 (log 尺度最小二乘)。

3 结果

3.1 判据门负结果链（五次实验）

实验	音色/编码器	红线	G1 a	G2 margin	G3	判定
M1.0	正弦/频带能量	6.17 (通过)	nan (n=0)	全程 0.000	无梯度	FAIL
M1.0 修正	同上 (全量 64 条)	6.17 (通过)	nan	全程 0.000	无梯度	FAIL
M1.1	带通噪声/mel+CNN	3.63 (通过)	+0.0033 可测	负值 (-0.006 → -0.047)	无梯度	FAIL
M1.2	谐波/mel+CNN (坍塌)	5.56 (通过)	+0.0237 可测	负值 (-0.011 → -0.096)	无梯度	FAIL
M1.2b	谐波/零训练 mel	7.09 (通过)	-0.0105 可测	≈0.000	无梯度	FAIL

失败模式分类（每次 FAIL 可诊断）：

- 模式一（M1.0）· 信号信息贫乏：正弦纯音的音高滑动 20-30Hz/帧 vs 频带 187Hz 宽，帧间频谱几乎不变→拷贝基线（保持上一帧）最优→ margin=0 合理；
- 模式二（M1.1）· 信号反预测性：带通噪声帧间频谱随机波动→拷贝基线强，模型试图预测不可预测的噪声成分→ margin 为负；
- 模式三（M1.2）· 表示坍缩：端到端联合训练的编码器输出坍缩到常数（逐维 std < 0.0031、范数恒定 0.337、帧间位移仅为幅度 1/40——诊断三件套），koop 在常数潜码上 loss=0 是完美坍缩解；
- M1.2b · 坍缩修复成功但 margin≈0：零训练编码器杜绝坍缩（潜码逐维 std 0.59-2.30 健康、帧间位移比 40 → 3.3），koop 可训（a=-0.0105 可测），但 margin≈0——预测不比拷贝好。

红线五次全 PASS（6.17/6.17/3.63/5.56/7.09）——频带能量类编码对瞬态冲击的敏感性是稳健性质；失败精确定位在「连续结构信息」上。

3.2 根因：mel 能量对频率滑动的响应微弱

M1.3 深化验证（多参数调制：x → 基频、y → 谐波亮度、速度 → 颤音，信息量 ×3；MLP 深网络 256×2 对照 koop）：红线 7.55 PASS；koop margin ±0.000 ($h^*=8$ ，微弱显著)；MLP margin ±0.000 ($h^*=7$)；量化无梯度。信息量 ×3 + 非线性容量都没把 margin 从 0 拉起 → mel 能量潜码口径下程序化音频判据不可测（本质负面结果）。

根因：mel 能量谱对基频小幅滑动的响应非线性且微弱——谐波峰在带间移动时能量重分配远小于帧间自相关 → 拷贝基线最优。出路三条（未实施）：波形级潜码（相位/波形细节对频率滑动敏感）、位置 → 能量大范围调制、真实音频数据。

3.3 两段式视界模型（B1 负结果导出的修正）

η 注入十档的 $h^*(\eta)$ 实测呈两段结构：小 η 区饱和于有限值（single≈3、koop≈4.5），大 η 区下降至 1。纯 T_{crash} 公式预测 $h^* \rightarrow \infty$ ($\eta \rightarrow 0$)， R^2 为负（-0.88/-0.48）——预注册负结果。

修正模型： $h^*(\eta) = \min(T_{\text{crash}}(a, \eta), h_{\text{sat}})$ —— h_{sat} 是任务随机性属性（与模型无关）， T_{crash} 是模型属性（由 $a + \eta$ 决定）。证据：koop（ a 低）饱和值更高（4.5 vs 3）（通过）； δ^* 一致性（通过）（两模型 0.147/0.096 同量级——同域共享崩坏阈值）。

T_{crash} 公式的适用条件由此划定：确定性系统（任务随机性可忽略）。与 X5 的判据边界补丁（cos 有效步数钝感）合并为完整的判据适用条件章节。

3.4 音画探针（最小可行演示）

3 条撞墙序列 → 结构化渲染帧（撞墙帧描红框）+ 立体声冲击音效（pan= 撞点 x 位置）→ ffmpeg 合成 MP4（12.5fps/24kHz，4.8 秒）。音画对齐机检断言全过（3 事件帧号 ↔ 样本位置 ±240 样本内）——音画严格同步、音源完全可溯、零外部数据依赖，为 H3 音画联合潜空间探针铺平管线。

4 讨论

负结果链的方法论价值：五次判据门实验的失败模式互不相同且均可诊断（信息贫乏/反预测性/表示坍缩），预注册门控防止了「在错误信号上反复调编码

器」的资源消耗。表示坍塌的三件套诊断（逐维 std、范数恒定性、帧间位移比）可复用于任何端到端编码器 + 动力学联合训练。

两段式模型的设计含义：低精度部署的可用性评估必须先估计任务随机性 (h_{sat})，再用 T_{crash} 预算模型侧改善空间—— h_{sat} 之上的改善才由模型决定，之下的差异全部被任务噪声淹没（呼应前期的判据边界补丁与闭环组合实验）。

音频判据的三条出路（按投入排序）：波形级潜码（保留相位信息，对频率滑动敏感）；位置→能量大范围调制（合成侧增大 mel 响应）；真实音频数据（内容丰富的声画配对）。H3 双 VAE 的音频编码器属于第三条的数据基础。

局限：音频合成信号均为人工设计（真实音频的频谱结构更复杂，负结果链不直接外推）；判据门阈值（红线 1.5、 R^2 0.8）为预注册约定值，非标定值；18 步窗口内 $h_{\{ \}}$ * 饱和值的区分度有限。

作者贡献声明：

参考文献：