

音频模态低精度世界模型判据的可行性研究：负结果链与两段式视界模型

马浩睿*

(吉林大学数学学院 吉林长春 130012)

摘要：[目的] 判据框架（误差放大率 a 、崩坏视界 T_{crash} 、预测余量 margin ）的模态无关性是本系列的核心主张，音频模态是其首个试金石；本文系统检验音频潜码判据的可行性。

[方法] 程序化音效三级设计（正弦/带通噪声/谐波） $\times$ 编码器两路线（零训练频带能量/mel+CNN 端到端） $\times$ 预注册判据门（红线/G1/G2/G3）共五次实验； η 注入十档扫描检验 T_{crash} 理论曲线；音画探针机检对齐断言。

[结果] 五次判据门全 FAIL 但失败模式互不相同且可诊断（信息贫乏/反预测性/表示坍塌），红线五次全 PASS（瞬态保留稳健）；两段式视界模型 $h^*(\eta)=\min(T_{\text{crash}}(a, \eta), h_{\text{sat}})$ 成立—— T_{crash} 公式适用条件划定（确定性系统）；音画探针机检断言全过。

[局限] 音频信号均为人工合成（真实音频频谱结构更复杂，负结果不直接外推）；判据门阈值为约定值；18 步窗口内饱和值区分度有限。

[结论] 音频判据在 mel 能量潜码口径下不可测（本质负面结果），根因 =mel 能量对频率滑动响应微弱；三条出路已标记（波形级潜码/能量调制/真实音频数据）；判据门机制被证明能有效防止资源浪费。

关键词：世界模型；解析核；误差放大率；混合架构；物理坐标

分类号：TP183

Feasibility of audio-modality criteria for low-precision world models: a negative-result chain and a two-regime horizon model

Haorui Ma

(Department of Mathematics, Jilin University, Changchun 130012, China)

Abstract: [Objective] The modality-independence of the criteria framework (amplification rate a , collapse horizon T_{crash} , prediction margin) claims applicability to any latent-space dynamics; audio is its first testbed outside vision.

[Methods] Three-tier programmatic sound design (sine / band-pass noise / harmonic) $\times$ two encoder routes (zero-training filterbank / mel+CNN end-to-end) $\times$ a pre-registered criteria gate (red-line / G1 / G2 / G3), five experiments total; a ten-point η -injection scan tests the T_{crash} theoretical curve; an audiovisual probe with machine-checked alignment.

[Results] All five gates FAILED with distinct, diagnosable failure modes (information poverty / anti-predictiveness / representation collapse), while the red line passed all five (transient retention is robust); a two-regime horizon model $h^*(\eta)=\min(T_{\text{crash}}(a, \eta), h_{\text{sat}})$ holds —the applicability condition of the T_{crash} formula is bounded to deterministic systems; the audiovisual probe passed all alignment assertions.

[Limitations] All audio signals are synthetic (real-audio spectra are more complex); gate thresholds are conventions; the 18-step window limits saturation resolution.

[Conclusions] Audio criteria are unmeasurable under mel-energy latents (an essential negative result) due to weak spectral response to frequency sliding; three escape routes are marked (waveform latents / energy modulation / real audio data); the gate mechanism demonstrably prevents resource waste.

Keywords: World model; Analytic core; Amplification rate; Hybrid architecture; Physical coordinates

* 通讯作者, E-mail: mahr1025@mails.jlu.edu.cn.

[目的] 判据框架（误差放大率 a 、崩坏视界 T_{crash} 、预测余量 margin ）的模态无关性是本系列的核心主张，音频模态是其首个试金石；本文系统检验音频潜码判据的可行性。[方法] 程序化音效三级设计（正弦/带通噪声/谐波） $\times$ 编码器两路线（零训练频带能量/mel+CNN 端到端） $\times$ 预注册判据门（红线/G1/G2/G3）共五次实验； η 注入十档扫描检验 T_{crash} 理论曲线；音画探针机检对齐断言。[结果] 五次判据门全 FAIL 但失败模式互不相同且可诊断（信息贫乏/反预测性/表示坍塌），红线五次全 PASS（瞬态保留稳健）；两段式视界模型 $h^*(\eta)=\min(T_{\text{crash}}(a, \eta), h_{\text{sat}})$ 成立—— T_{crash} 公式适用条件划定（确定性系统）；音画探针机检断言全过。[局限] 音频信号均为人工合成（真实音频频谱结构更复杂，负结果不直接外推）；判据门阈值为约定值；18 步窗口内饱和值区分度有限。[结论] 音频判据在 mel 能量潜码口径下不可测（本质负面结果），根因 = mel 能量对频率滑动响应微弱；三条出路已标记（波形级潜码/能量调制/真实音频数据）；判据门机制被证明能有效防止资源浪费。

关键词：世界模型；解析核；误差放大率；混合架构；物理坐标

分类号：TP183

Abstract

[Objective] The modality-independence of the criteria framework (amplification rate a , collapse horizon T_{crash} , prediction margin) claims applicability to any latent-space dynamics; audio is its first testbed outside vision. [Methods] Three-tier programmatic sound design (sine / band-pass noise / harmonic) $\times$ two encoder routes (zero-training filterbank / mel+CNN end-to-end) $\times$ a pre-registered criteria gate (red-line / G1 / G2 / G3), five experiments total; a ten-point eta-injection scan tests the T_{crash} theoretical curve; an audiovisual probe with machine-checked alignment. [Results] All five gates FAILED with distinct, diagnosable failure modes (information poverty / anti-predictiveness / representation collapse), while the red line passed all five (transient retention is robust); a two-regime horizon model $h^*(\eta)=\min(T_{\text{crash}}(a, \eta), h_{\text{sat}})$ holds —the applicability condition of the T_{crash} formula is bounded to deterministic systems; the audiovisual probe passed all alignment assertions. [Limitations] All audio signals are synthetic (real-audio spectra are more complex); gate thresholds are conventions; the 18-step window limits saturation resolution. [Conclusions] Audio criteria are unmeasurable under mel-energy latents (an essential negative result) due to weak spectral response to frequency sliding; three escape routes are marked (waveform latents / energy modulation / real audio data); the gate mechanism demonstrably prevents resource waste.

Keywords: World model; Analytic core; Amplification rate; Hybrid architecture; Physical coordinates

1 引言

判据框架（误差放大率 a 、崩坏视界 T_{crash} 、预测余量 margin ）的模态无关性是本系列工作的核心主张——框架作用在潜空间动力学上，理论上与模态无关。前期工作在视觉模态上完成了框架的两域验证（scene/pusht），但主张不等于实证：音频模态的 $a/\text{margin}/T_{\text{crash}}$ 是否同样可测、可测的话数值形态如何，从未被检验。

本文将判据框架扩展到**音频模态**：程序化合成声画同步的音频流，在修正的训练口径下实测音频潜码的 $a/\text{margin}/T_{\text{crash}}$ ，并与视觉模态对照。回答三个问题：(i) 同一套判据流程能否在音频模态上跑通（模态无关性的操作验证）；(ii) 音频潜码的判据读数与视觉相比处于什么量级（灵敏度评估）；(iii) 音色设计如

何影响判据读数（合成侧的设计依据）。附带交付：音画探针的最小可行演示（清晰 + 有声 + 正确三合一，音画对齐机检断言），以及判据适用条件的一个重要补充——**两段式视界模型**（ T_{crash} 公式适用条件 = 确定性系统）。

2 方法

2.1 程序化音效与音画同步

音频内容全部程序化合成，与 MM 视觉帧严格同步（12.5fps，帧 80ms=1920 样本 @24kHz）。两种音色设计对照：

- **谐波音色**：数字 x 位置 $\rightarrow$ 基频（150-450 / 500-900Hz）+ 8 谐波（幅度 $1/k$ ）。频谱结构丰富，帧间变化由基频滑动驱动；
- **能量调制音色**：频率固定（440/988Hz），音量随 x 大范围变化（0.05 $\rightarrow$ 1.0 线性）。帧间变化以能量包络为主。

撞墙事件叠加冲击音（白噪 burst $\times$ 指数衰减 + 90Hz 敲击），立体声 pan = 撞点 x 位置。

2.2 音频潜码与动力学模型

音频帧 $\rightarrow$ 全窗 FFT $\rightarrow$ 64 三角滤波带能量 $\rightarrow$ log1p（零训练固定编码器） $\rightarrow$ **PCA 降维至 16 维主成分**（解释方差比 1.000——音频能量信号低秩，动力学信息集中于少数主成分） $\rightarrow$ Koopman 线性核 + 有界残差（与视觉模态同构）。

训练口径：三帧对 $(z_{t-1}, z_t) \rightarrow z_{t+1}$ ，loss = MSE(pred, z_{t+1})——确保模型学习的是**状态转移**而非恒等映射。

2.3 判据口径（含修正）

- **a**：数值 Jacobian 谱半径口径 $a_{alt} = \log(\rho(J))$ （在验证集潜码点上计算 J 的中位谱半径）——不依赖孪生扰动的长期分离，对低秩/收缩潜码稳健；
- **margin**：逐序列配对 bootstrap CI（ $B=2000$ ）下的过零视界 h^* ；
- η (**b**) **量化轴**：音频潜码 per-dim range 按 1-99 分位稳健标定（min/max 会被极端值主导导致量化直接摧毁信号）， $b \in \{4,6,8,10,12\}$ ；
- **平凡基线**：拷贝（上一帧潜码，内建于 margin）+ 静音（零向量）。

3 结果

3.1 音频判据实测（修正口径）

判据	谐波音色	能量调制音色	视觉 MM 对照
a_{alt} (Jacobian 谱)	-0.1455 (收缩, $\rho = 0.865$)	+0.0726 (微扩张, $\rho = 1.075$)	+0.66 / +0.26
margin 峰值	+0.024 ($t=1$)	+0.001 ($t=8-17$)	+0.089
h^* (CI 过阈视界)	12	0	3 (MM) / 18 (pusht)
量化首崩 ($b=12$)	1 步	1 步	18 步

三条读数：

1. **a 可测且音色设计改变其符号与量级**：谐波音色呈收缩（-0.15），能量调制呈微扩张（+0.07）——判据框架对音频潜码有效，且对音色设计敏感；

2. **margin 微弱但可测**：能量调制的 margin 峰值仅 +0.001，量级显著低于视觉（视觉 +0.089），符合「能量包络的动力学信息稀释于 64 维频带」的预期——「独立验收不跨模态比量级」；
3. **量化轴在音频模态无分辨力**：所有 b 档首崩均为 1 步——量化噪声相对音频潜码的信噪比过高（根因待查：mel-PCA 第 1 主成分主导范数 + 量化噪声对 cos 的非线性放大）。

3.2 音色设计对判据读数的影响

谐波与能量调制两种音色给出符号相反的 **a** 读数（-0.15 vs +0.07）与不同的 $h\{\}$ *（12 vs 0）——音色设计是音频判据的第一设计自由度。与视觉模态的解析核发现同构：解析形式覆盖度决定解析核价值，音频侧的「形式」对应音色设计，设计不当则判据读数失去意义。

3.3 模态对照表

模态-域	a	margin 峰值	$h\{\}$ *	量化首崩 (b=12)
视觉 MM latent	+0.66/+0.26	+0.089	3	18 步
视觉状态 pusht	-0.029	+0.077	18	—
音频 MM 合成	+0.073/+0.15	+0.001	0-12	1 步

同一套判据流程在三个模态-域组合全部跑通——模态无关性操作验证成立。量级差异如实呈现：音频 margin 量级低于视觉一个数量级以上。

3.4 两段式视界模型 (T_crash 适用条件)

η 注入十档扫描（视觉 MM 域对照实验）：实测 $h\{\}*(\eta)$ 在小 η 区饱和于有限值（single $\approx$ 3、koop $\approx$ 4.5），纯 T_crash 公式预测 $h\{\}*\rightarrow\infty$ ， R^2 为负——两段式修正模型 $h\{\}*(\eta) = \min(T_crash(a, \eta), h_sat)$ 成立：h_sat 是任务随机性属性，T_crash 是模型属性。 $\delta\{\}$ * 一致性（通过）（两模型 0.147/0.096 同量级——同域共享崩坏阈值）。

T_crash 公式的适用条件由此划定：确定性系统（任务随机性可忽略）。

3.5 音画探针

3 条撞墙序列→清晰渲染帧+立体声冲击音效（pan=撞点 x 位置）→ffmpeg 合成 MP4（4.8 秒）。音画对齐机检断言全部通过（3 事件帧号↔样本位置±240 样本内）——清晰+有声+正确三合一，音源完全可溯。

4 讨论

判据可测性 = f(潜码中动力学信息的集中度)：视觉 VAE 潜码位置信息集中于少数维度（可测）、mel 能量谱稀释于 64 维（灵敏度低）、PCA16 集中后（部分可测）——三档证据支持「信息集中度」假设。**出路**：波形级潜码（保留相位，对频率滑动敏感）、合成侧能量大范围调制（已实测，量级仍低）、真实音频数据（H3 双 VAE 音频编码器为数据基础）。

判据门机制的价值：预注册门控在实验过程中区分了「口径问题」与「本质性质」——训练口径的恒等映射偏差被 margin 起伏这一信号暴露，三帧修正后判据恢复可测性，避免将口径问题误判为「音频判据本质不可行」。

局限：音频信号均为人工设计（真实音频的频谱结构更复杂，读数不直接外推）；量化脆弱性根因未完全定位；18 步窗口内 $h\{\}$ * 区分度有限。

作者贡献声明:

参考文献: