

低精度世界模型的可用性判据框架与设计可行性：从测量到架构

马浩睿*

(吉林大学数学学院 长春 130012)

摘要: [目的] 低精度部署下的世界模型何时可用、如何设计, 缺乏可操作判据; 本文旨在建立一套预注册的可用性判据框架, 并通过受控实验检验各类设计手段的实际效果。

[方法] 以固定窗口孪生轨迹率尺度 a 、多步余量 margin 、量化噪声 η (b) 与崩坏视界 T_{crash} 、实时闭环三判据构成框架, 在两级模型规模 (隐层 192/480) 与两个数据域 (Moving MNIST、OGBench scene) 上, 在损失塑形、更新几何与架构三个层级上进行同口径受控对照, 并接入外部渲染模型构建实时闭环。

[结果] 判据在真实域可测且有鉴别力 (量化崩坏视界横跨 $1 \rightarrow 41$ 步); h^* 由数据分布决定 ($2 \rightarrow 10$ 步); 准确-稳定权衡的瓶颈只能在架构层突破: 有界残差 Koopman 架构通过预注册门限 (GO 区间 $s \in [0.375, 0.410]$), 损失塑形与更新几何则分别导致精度崩塌与更新失效; 渲染层遵循环路外原则 (合规时结果逐位一致, 违规时 a 降至 0.03); 闭环系统在 8GB 单卡上运行于 59.1 FPS, 崩坏预警重置显著延长有效时长。

[局限] 关键数字仅在隐层 192/480 两级重复计算; 真实域限于自采数据; 渲染层仅完成域内调通, 新一代音画双 VAE 尚待接入; 解析崩坏式在小 a 区偏保守。

[结论] 多步崩坏不可消除但可管理: 数据分布与架构是延长可用视界的两个主要途径, 闭环预警与短视界使用是必要配合; 可用性边界可在设计阶段由公式计算。

关键词: 世界模型; 低精度推理; 误差放大率; Koopman 算子; 实时闭环

中图分类号: TP183

Usability criteria and design feasibility for low-precision world models: from measurement to architecture

Haorui Ma

(School of Mathematics, Jilin University, Changchun 130012, China)

Abstract: [Objective] When is a world model usable under low-precision deployment, and how should it be designed? We build a pre-registered usability-criteria framework and examine which design levers are effective under identical measurement.

[Methods] The framework combines a fixed-window twin-trajectory amplification rate a , multi-step margin, quantization noise η (b) with collapse horizon T_{crash} , and three closed-loop criteria (latency budget, sustained frame rate, closed-loop success). Experiments span two model scales (hidden 192/480) and two data domains (Moving MNIST; OGBench scene), comparing three layers of intervention: loss shaping, update geometry, and architecture, plus an external renderer attached out-of-loop.

[Results] The criteria are measurable and discriminative on the real domain (quantization collapse horizon spanning $1 \rightarrow 41$ steps); h^* is determined by the data distribution ($2 \rightarrow 10$ steps); the accuracy-stability trade-off can only be resolved at the architecture layer: a bounded-residual Koopman architecture passes the pre-registered gate (GO interval $s \in [0.375, 0.410]$) while loss shaping and update geometry fail (margin collapse; ineffective updates); the renderer obeys the out-of-loop principle (results are bit-identical when compliant; a falls to 0.03 when violated); the closed loop runs at 59.1 FPS on a single 8GB GPU, and collapse-warning resets yield a significant effective-horizon gain.

[Limitations] Key numbers are replicated at two hidden sizes only; the real-domain result uses self-collected data; the renderer is an in-domain integration with a next-generation audio-video VAE pending; the analytic collapse formula is conservative by 3-18x at small a .

[Conclusions] Multi-step collapse cannot be eliminated but can be managed: data distribution and architecture extend the usable horizon, closed-loop warning and short-horizon usage are necessary components, and the usability envelope can be computed from formulas at design time.

Keywords: World model; Low-precision inference; Amplification rate; Koopman operator; Real-time closed loop

1 引言

世界模型与图像/语言模型的关键差别在于**推理即推演**：它不在单点上输出答案，而是在潜空间中沿动力学自回归生成一条轨迹，并据此支撑规划与控制。当部署目标转向低精度硬件时，量化误差并非一次性叠加于输出，而是反馈进状态并沿轨迹指数传播。已有工作把「显式考虑长程潜空间 rollout 误差累积的量化方法」列为开放问题^[1]，而世界模型表述本身自 Ha 与 Schmidhuber 以来即以「学习推演」为核心主张^[2]，Dreamer 系列进一步确立了潜空间 rollout 的标准范式^[3]。对于一条 rollout 在低精度下还能使用多久、何时崩坏以及崩坏后如何处理，目前仍缺乏可操作的判据。

本文围绕这一问题做了两件事。第一，建立并**预注册**一套可用性判据框架：误差放大率 $\mathbf{a}$ （固定绝对窗口的孪生轨迹率尺度）、多步预测余量 $\mathbf{margin}$ （对拷贝基线的逐视界优势）、量化噪声 η ($\mathbf{b}$) 与崩坏视界 T_{crash} 、以及实时闭环三判据（时延预算、持续帧率、闭环成功率）。全部判据先通过自检与噪声底标定后投入使用。第二，用这套框架做两组受控实验：在合成域与真实物理任务^[4]上检验判据的可测性与鉴别力；在损失塑形、更新几何与架构三个层级上，以同一评测口径检验何种手段能在不牺牲精度的前提下改善放大率。

贡献四条：(i) 判据框架及其在真实物理任务上的可测性与鉴别力验证；(ii) 准确-稳定权衡的三层机制结论：权衡瓶颈只能在架构层突破，损失塑形与更新几何两条替代路线在受控实验中均未通过；(iii) 有界残差 Koopman 架构：在两级模型规模上通过预注册成功门限，使可用性设计由经验尝试转变为带区间的工程选择；(iv) 8GB 单卡上的实时闭环系统与渲染层环路外原则的实验证明。

2 方法

2.1 判据框架

误差放大率 $\mathbf{a}$ ：采用孪生轨迹口径：对同一初始状态注入相对扰动 $\varepsilon = 10^{-4} \cdot \|\mathbf{z}\|$ ，沿真实动作序列同步推演， $\mathbf{a}$ 为 $\log(d_{t_1}/d_{t_0})/(t_1 - t_0)$ 的中位数，窗口固定为绝对步 [8,20]（相对窗口随实验臂漂移，无法用于跨模型比较）。显著性判据为 $\mathbf{a} - 2 \cdot \text{SE} > 0$ ，噪声底取先验上界与样本 χ^2 上界的较大者。

精度余量 $\mathbf{margin}$ ：自回归 rollout 的单步预测对「拷贝上一帧」基线的余弦余量，逐视界报告并配对 bootstrap ($B=2000$) 给出 95% CI；优势边界 h^* 定义为 CI 下界大于 0 的最大视界。

精度上限 η ($\mathbf{b}$)：位宽 $\mathbf{b}$ 下逐维量化步 $\Delta_d = \text{range}_d/(2^b - 1)$ ， $\eta(\mathbf{b}) = \sqrt{\sum_d \Delta_d^2/12}$ ；崩坏视界解析式为 $T_{\text{crash}} = \ln(1 + \delta^*(e^{\mathbf{a}} - 1)/\eta)/\mathbf{a}$ ， $\delta^* = 1$ 。该式给出保守下界（假设误差按最坏方式相干积累），实测崩坏视界普遍晚于解析值。

实时闭环三判据：每步端到端时延（含渲染，预算在配置中给定）；持续运行的稳定帧率（非峰值）；闭环成功率（rollout 与真值轨迹的逐步余弦 ≥ 0.9 的步数）。崩坏预警组件 CollapseWarner 提供两个接口：预飞行（由 $\mathbf{a}$ 、 η 解析预测崩坏视界）与在线检查（潜向量范数偏离训练分布 3σ 报警）。

* Corresponding author, E-mail: mahr1025@mails.jlu.edu.cn

2.2 实验设计

两级规模：最小集（隐层 192，约 4 万参数）用于扫描与机制判定；主模型（隐层 480）复算关键结论。**两个数据域：**合成 Moving MNIST^[5]（灰度 64×64，VAE 潜空间 64 维）；真实物理操纵任务 OGBench scene^[4]（多物体接触：抓放、抽屉推拉、按钮，40 维状态，本机自采随机策略与脚本策略各 360 回合）。**数据配比是受控变量：**同一模型分别用随机策略与脚本策略数据训练，以分离数据分布对 h^* 的影响。

设计轨三层对照：目标函数层（a-supervision 损失， $\mu \in \{0.1, 0.3, 1, 3, 10\}$ 扫描）、更新几何层（放大率守卫：Adam 每步更新后以固定探针批测有限差分放大率，若放大率上升则步长折半并回溯，重复三次仍违规则拒绝该步）、架构层（解析 Koopman 核^[6]与有界残差组合，s 为连续参数，K 受谱范数惩罚 ρ_0 ）。三层共用同一数据、同一评测口径（margin 与 a 的计算函数完全复用）。

渲染层与环路外原则：世界模型推演全程在自家潜空间，仅在输出端经一次性对齐映射（ $z_{\text{self}} \rightarrow z_{\text{ext}}$ ）接外部渲染模型（Qwen-Image VAE^[7]）。对照实验包含合规接法（每步渲染出画、不反馈）与违规接法（渲染帧重编码回潜空间）。

预注册与可复算：全部实验的判据在运行前写定；结果以 JSON 落盘，报告数字由脚本从产物中读取；关键结论在主模型规模上重复计算。

3 结果

3.1 判据框架：在合成域建立、在真实域检验

最小集上，无约束模型 $a=+0.667$ 、 $\text{margin}=+0.092$ （5 seeds）。判据的判别力在真实域得到检验：OGBench scene 上，三件套在随机策略与脚本策略两种数据臂上均可测量： $a=+0.007 \sim +0.022$ （各 2/3 seed 显著）；量化轴崩坏视界横跨 $b=4 \rightarrow 12$ ：解析为 $1 \rightarrow 41$ 步，实测中位为 $1 \rightarrow 34$ 步（全部落在 151 步可测视野内）。作为对照，弱鉴别环境（LeWM tworoom^[8]）三件套可测，但 a 与 0 不可区分（ $+0.021 \pm 0.023$ ），崩坏视界虽随位宽变化（ $1 \rightarrow 28$ 步），floor 判据未通过。这构成一组「可测且有鉴别力」与「可测但无鉴别力」的对照，表明判据框架能够区分判据失效与任务本身不包含可识别信息这两种情形。

3.2 h^* 由数据分布决定

同一环境、同一模型容量下，仅将训练数据从随机策略换成脚本策略轨迹，优势边界 h^* 由 2 步延长至 10 步（margin 由衰减型 $+0.037 \rightarrow +0.012$ 变为平缓型约 $+0.02$ 并持续到 $h10$ ）。 h^* 并非任务的固有属性，而由数据分布决定。这是崩坏管理的第一条路线：延长 h^* 的主要途径在数据侧。

3.3 设计轨：权衡瓶颈只能在架构层突破

目标函数层（瓶颈）：以有限时间放大率进损失的 a-supervision， μ 从 0.3 升至 1 时 a 由 0.659 降至 0.319，margin 同时由 $+0.079$ 降至 -0.007 ：权衡曲线在 $a \in (0.32, 0.66)$ 、 $\text{margin} > 0$ 的内部区间完全空缺，且该瓶颈在隐层 96/192/480 三档均出现，不随模型规模改变。

更新几何层（更新失效/回推）：放大率守卫在无约束 MLP 上与普通 Adam 的更新结果逐位一致（a 同为 $+0.668$ 最小集 / $+0.663$ 主模型，400 步仅触发 14-22 次）：普通 MLP 的更新方向不经过增大放大率的区域，说明放大率是解的属性而非更新路径的属性；在 Koopman 架构上守卫在约 73% 的步数上触发，将架构取得的点推回收缩区（最小集 a 被推至 -0.021 ；主模型 a 由 $+0.344$ 降至 -0.043 ）。该结果在两级规模上均复现。

架构层（GO）： $p = Kb + s \cdot \tanh(r(z))$ （K 为受谱惩罚的线性核，残差输出有

界)。不加任何 a 监督, s 参数在最小集上给出 ($a=+0.239$, $\text{margin}=+0.077$) ($s=0.5$) 至 ($a=-0.021$, $+0.034$) ($s=0.1$) 的连续曲线, 覆盖了损失塑形无法到达的内部区间。主模型复算通过预注册相对判据 ($a \leq 0.5 \times$ 、 $\text{margin} \geq 0.75 \times \text{single}$), GO 区间为 $s \in [0.375, 0.410]$ (相邻网格点连续通过门限, 且呈单调剂量-反应关系)。

可分离性: 在精度口径下 ρ_0 与位宽不存在交互: 最小集上 $\rho^*(b)$ 为常数、量化惩罚与 ρ_0 几乎无关 (10.2 mpp 三档同值); 主模型上三档 ρ_0 的 a 与 margin 逐位相同 (宽残差起主导作用, 谱约束无影响)。「压低 a 即可免费获得位宽」的判断只在崩坏时刻口径下成立。该结论与 GO 区间均在主模型宽度复算。

3.4 渲染闭环: 环路外原则与实时账本

环路外原则的实验证明: 合规接法 (每步渲染出画、不反馈) 下动力学扩张率与不接渲染层逐位一致 (+0.662833 两次); 违反环路 (渲染帧重编码回喂) 仅一步即使 a 由 +0.66 降至 +0.03。环路外原则由此从设计约定得到受控实验验证。

对齐可行性: 跨架构对齐映射 (自家 64 维潜码 $\rightarrow$ 外部 VAE $16 \times 16 \times 16$ 潜码) 在 5 seeds 上达 22.43 ± 0.02 dB, 较常数基线高 4.69 dB (门限 3 dB); 距外部往返天花板 47.58 dB 尚差 25 dB, 这一差距是跨架构映射的实际代价, 也表明仍有优化空间。

实时账本 (8GB 单卡): 端到端 18.15ms/步 (动力学 0.46 + 对齐映射 0.34 + 外部解码 17.28 + 预警检查 0.07), 低于 30 FPS 预算 33ms; 持续闭环时潜空间运行于 3396 FPS, 带外部渲染时为 59.1 FPS; 瓶颈完全位于渲染解码环节 (95%)。

闭环崩坏管理: 128 序列四臂对照, 预警重置相对开环显著延长有效步数 ($\Delta = +0.10$ 步, $CI [+0.05, +0.16]$); 同重置次数的定期重置无法复现该增益 ($\Delta = -0.10$, CI 不含 0): 预警的价值在于时机选择, 这与闭环系统的主要失效模式是缺乏对自身崩坏的感知这一认识一致。解析预飞行预测崩坏视界 4 步, 实测首崩中位 2 步, 二者同量级, 解析预测偏保守。

4 讨论

管理多步崩坏的五条可能路线 (本文均有实测结果对应): 数据分布 (延长 h^* 的主要途径)、架构层 (唯一能压低 a 的层级)、闭环真观测纠正 (截断误差积累)、预警与回退 (崩坏不可避免时的保护机制)、短视界使用 (在 h^* 内决策的滚动重规划方式)。两条路线在受控实验中被排除: 损失塑形与更新几何。

与相关工作的关系: 解析结构与神经网络的结合已有 Hamiltonian 神经网络^[9]、Lagrangian 神经网络^[10]等范式, 将守恒律写入网络; 本文的架构层结果为同一思想提供了低精度场景下的依据: 解析核的放大率可由公式直接设计, 使「可承载位宽」在设计时即可计算, 可用性评估也由实测结果汇总转变为设计阶段的工具。与生成式渲染模型的衔接^{[7][11]}定位为输出端 (环路外), 这类模型以物理先验注入的形态依赖真实视频数据域, 相关衔接留作后续工作。

局限: (i) 关键数字仅在隐层 192/480 两级重复计算, 更大规模尚未验证; (ii) 真实域结论限于 OGBench scene 的自采数据 (随机/脚本策略), 官方策略数据域待接入; (iii) 渲染层当前为域内调通版 (Qwen VAE), 新一代音画双 VAE (MiniMax-H3^[11], 2.6B 视频 VAE + 音频 VAE 已下载待接) 的正式接入与复测正在进行; (iv) 解析崩坏式在小 a 区偏保守 3-18 倍, 适用条件已在对照表中记录。

作者贡献声明:

马浩睿提出研究问题与研究采用的核心观点和方法, 设计总体研究框架, 完成全部代码实现与实验 (部分代码在生成式 AI 工具辅助下编写, 详见人工智能使用说明); 提供、采集与分析全部实验数据; 撰写、修改并审定论文全文。

人工智能（AI）使用说明

本研究在代码实现与论文撰写过程中使用了生成式人工智能工具（豆包 Doubao 大语言模型、DeepSeek-Flash、GLM-5.3-Flash），使用范围与边界声明如下。

1. 代码：部分代码由作者与 AI 协作完成，其中豆包 Doubao、DeepSeek-Flash 参与代码生成；全部代码均经作者逐行核对与运行验证。
2. 论文：部分论文内容在 AI 辅助下起草、润色与语言校对；研究选题、科学假设、实验设计与结果结论由作者作出，全部实验数据由作者采集与分析。

数据与代码可用性

全部实验数据产物（logs/ 下 JSON 日志）、复现脚本与核心代码可应要求提供。

5 结论

多步崩坏不可消除但可管理。数据分布与架构是延长可用视界的两个有效途径：数据分布将优势边界 h^* 由 2 步延长至 10 步，有界残差 Koopman 架构在 GO 区间 $s \in [0.375, 0.410]$ 内通过预注册门限；损失塑形与更新几何被对照实验排除。闭环预警与短视界使用是必要配合，渲染层环路外原则得到逐位一致的验证；可用性边界可在设计阶段由公式算出。

参考文献：

- [1] FU Z Q, ZHAO T Y, HAN K, et al. An empirical study of world model quantization[EB/OL]. arXiv:2602.02110, 2026.
- [2] HA J, SCHMIDHUBER J. World models[EB/OL]. arXiv:1803.10122, 2018.
- [3] HAFNER D, PASUKONIS J, BAIWAN H, et al. Mastering diverse domains through world models[EB/OL]. arXiv:2301.04104, 2023.
- [4] PARK S, CHOI K, LEE J, et al. OGBench: benchmarking offline goal-conditioned RL[EB/OL]. arXiv:2410.20092, 2024.
- [5] SRIVASTAVA N, MANSIMOV E, SALAKHUTDINOV R. Unsupervised learning of video representations using LSTMs[C]//Proceedings of the 32nd International Conference on Machine Learning (ICML). 2015: 843-852.
- [6] KOOPMAN B O. Hamiltonian systems and transformation in Hilbert space[J]. Proceedings of the National Academy of Sciences, 1931, 17(5): 315-318.
- [7] QWEN TEAM. Qwen-Image technical report[EB/OL]. arXiv:2508.02324, 2025.
- [8] MAES L, LE LIDEC Q, SCIEUR D, et al. LeWorldModel: stable end-to-end joint-embedding predictive architecture from pixels[EB/OL]. arXiv:2603.19312, 2026.
- [9] GREYDANUS S, DZAMBA M, YOSINSKI J. Hamiltonian neural networks[EB/OL]. arXiv:1906.01563, 2019.
- [10] CRANMER M, LEIHWELL S, SANCHEZ-GONZALEZ A. Lagrangian neural networks[EB/OL]. arXiv:2003.04630, 2020.
- [11] MINIMAX. MiniMax-H3 model card[CP/OL]. Hugging Face, 2026. <https://huggingface.co/MiniMaxAI/MiniMax-H3>.